TECH CHALLENGE — FASE 2 · PÓS-GRADUAÇÃO DATA ANALYTICS

Prevendo a Qualidade do Vinho com Dados

Uma leitura executiva da análise exploratória e dos modelos preditivos desenvolvidos a partir do Wine Quality Dataset.

Storytelling da Análise Exploratória de Dados & Resultados de Modelagem

CONTEXTO

Avaliar a qualidade do vinho hoje é lento e depende de especialistas



Análise sensorial tradicional

Especialistas avaliam aroma, sabor, acidez e equilíbrio prova a prova.



Processo subjetivo e demorado

O resultado depende da experiência de quem avalia — difícil de padronizar em escala.



Uma nova alavanca: os dados

Dados físico-químicos, já medidos durante a produção, podem antecipar a qualidade final.

Objetivo do projeto: treinar um modelo preditivo capaz de classificar um vinho como Alta Qualidade a partir apenas de suas características físico-químicas.

A BASE DE DADOS

O que temos em mãos

1.143

amostras de vinho tinto analisadas

11

variáveis físico-químicas por amostra

2

classes finais: Alta vs Baixa/Média

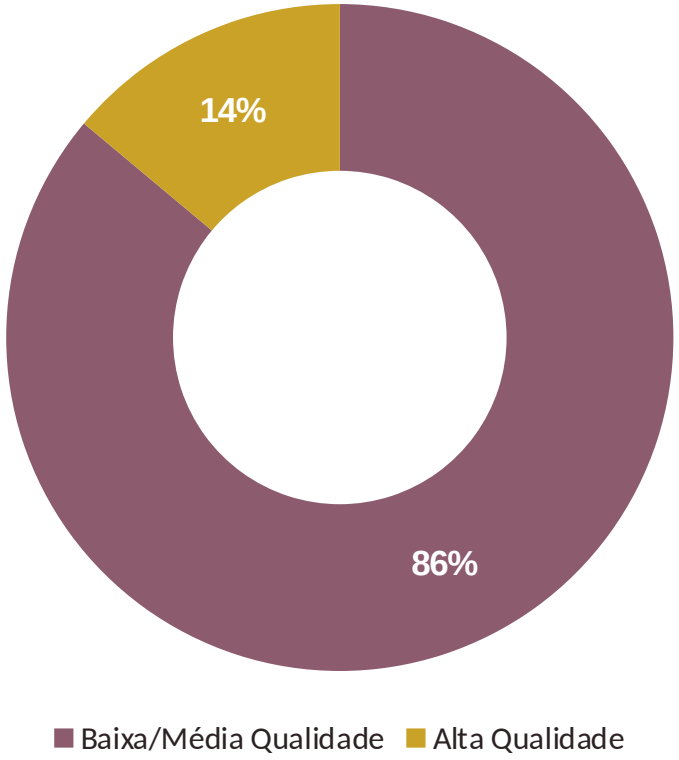
0

valores faltantes na base

Como simplificamos o problema: a nota original de qualidade (3 a 8) foi convertida em uma classificação binária — **Alta Qualidade (nota ≥ 7)** ou **Baixa/Média Qualidade (nota < 7)**.

INSIGHT 01 · PANORAMA GERAL

Vinhos de alta qualidade são raros na nossa amostra



86%

das amostras (984) são de Baixa/Média Qualidade

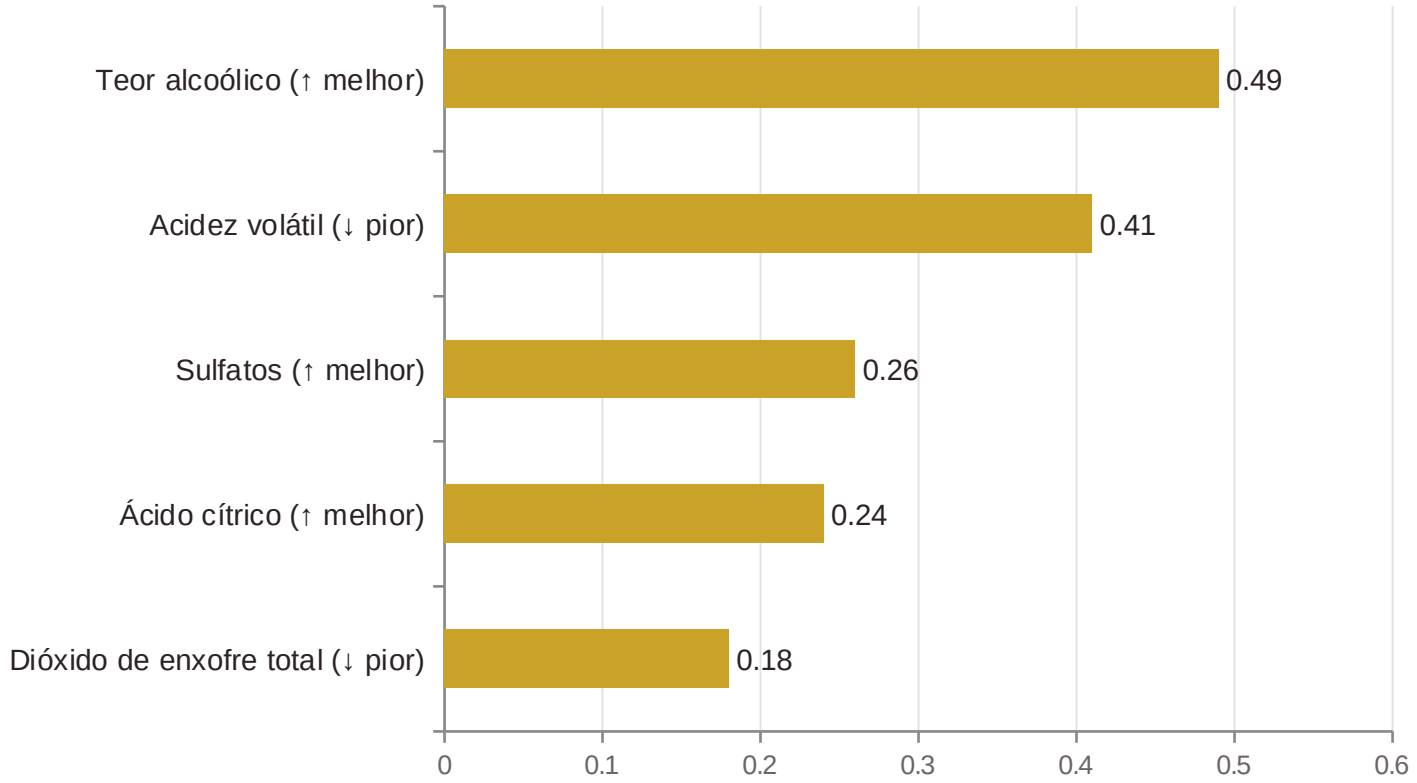
14%

das amostras (159) são de Alta Qualidade — a classe que mais nos interessa prever bem

Por que isso importa: um modelo "preguiçoso" que sempre apostasse em Baixa/Média Qualidade já acertaria 86% das vezes, sem aprender nada útil. Por isso avaliamos os modelos por métricas mais rigorosas do que a simples taxa de acerto.

INSIGHT 02 · FATORES DE QUALIDADE

Álcool e acidez volátil são os sinais mais fortes de qualidade



Leitura do gráfico

Barra maior = relação mais forte com a nota de qualidade (em qualquer direção).

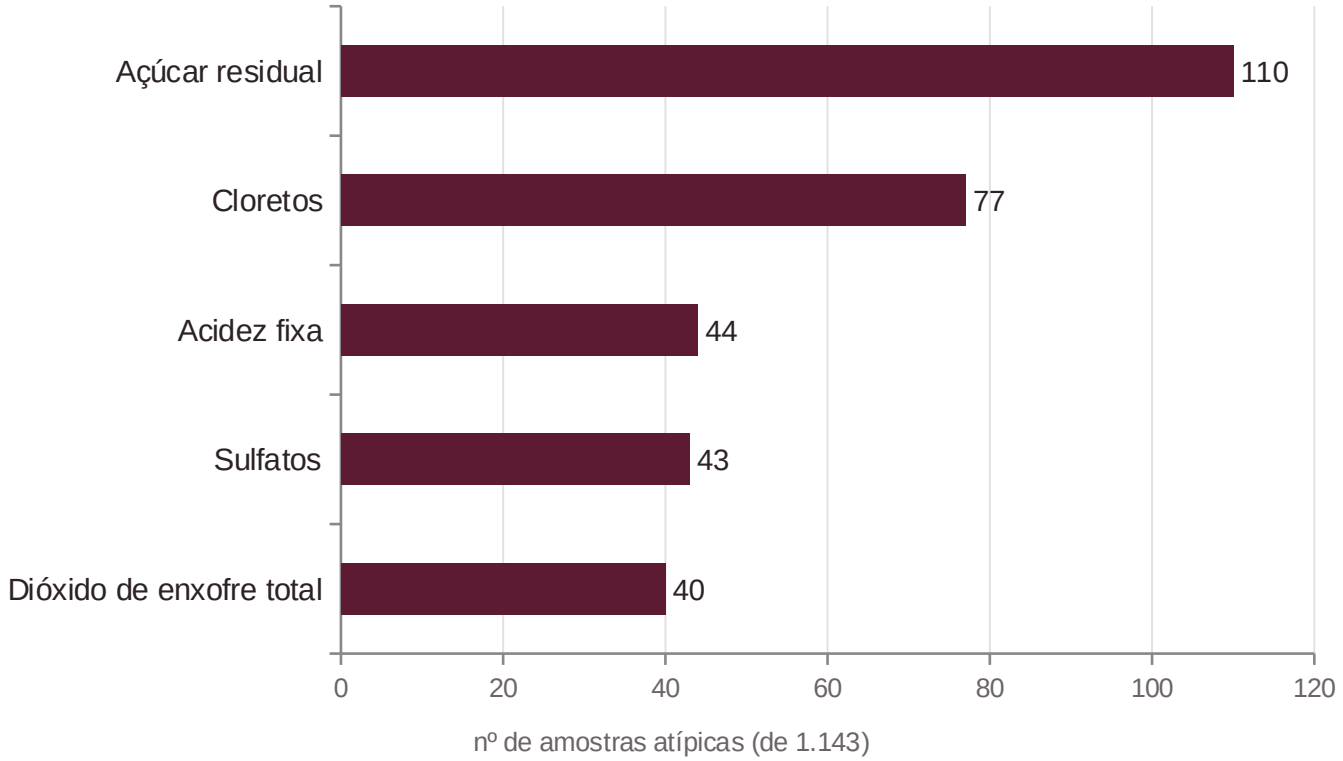
(↑ melhor): quanto maior o valor dessa variável, maior a nota tende a ser.

(↓ pior): quanto maior o valor dessa variável, menor a nota tende a ser.

Na prática: vinhos com maior teor alcoólico, menor acidez volátil (associada a defeitos de fermentação) e mais sulfatos tendem a ser mais bem avaliados.

INSIGHT 03 · CONSISTÊNCIA DA PRODUÇÃO

Alguns lotes fogem bastante do padrão da produção



Açúcar residual é a variável com mais valores atípicos: cerca de 1 em cada 10 amostras (110 de 1.143) foge bastante do padrão típico do lote.

Cloretos aparece em seguida (77 amostras) — ambos merecem atenção extra no controle de processo, pois têm grande influência no equilíbrio de sabor do vinho.

METODOLOGIA

Do dado bruto até a previsão

1

Organização dos dados

Limpeza, checagem de consistência

2

Análise exploratória

Distribuições, correlações, outliers

3

Padronização e novas features

Mesma escala para todas as variáveis

4

Treino dos modelos

3 algoritmos treinados e comparados

5

Avaliação e escolha final

Métricas de negócio, não só acerto geral

MODELAGEM

Testamos três abordagens de aprendizado de máquina



KNN

K-Vizinhos Mais Próximos

Classifica um vinho comparando-o aos vinhos mais parecidos já conhecidos pelo modelo.



Árvore de Decisão

Decision Tree

Aprende uma sequência de perguntas do tipo “se-então” sobre as características do vinho.



Random Forest

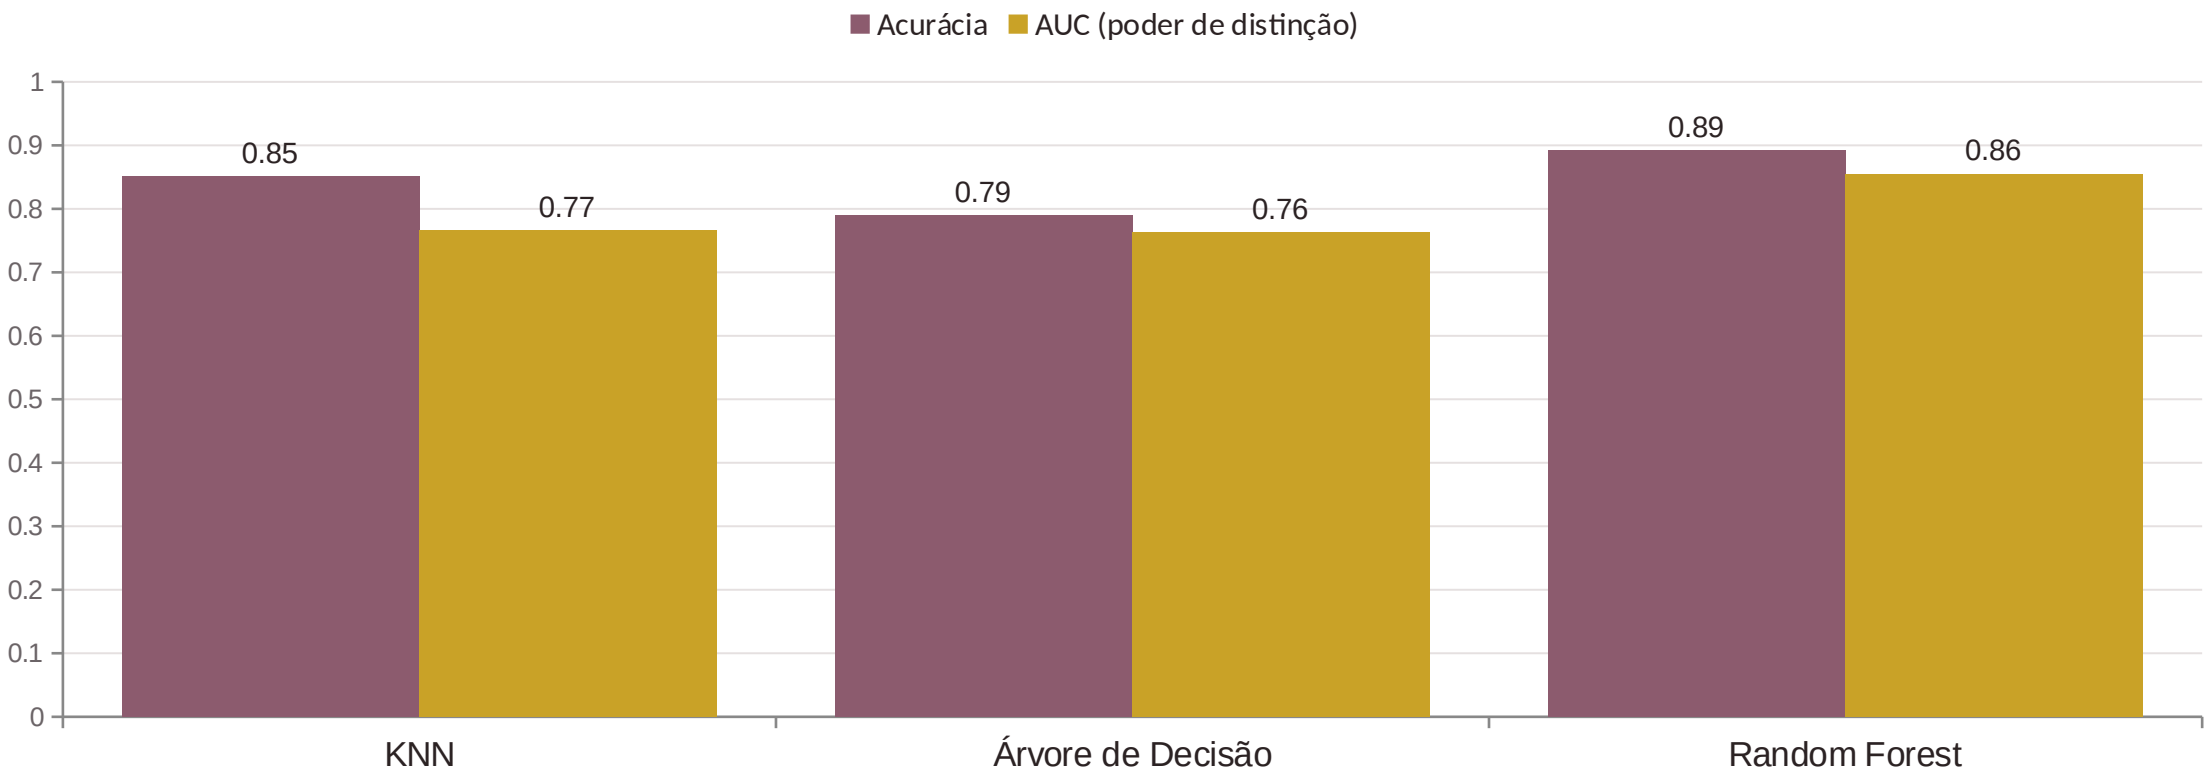
Floresta Aleatória

Combina centenas de árvores de decisão diferentes e junta os “votos” para decidir.

Todos os três foram treinados com os mesmos dados (70% treino / 30% teste) e comparados pelas mesmas métricas.

RESULTADOS

Random Forest teve o melhor desempenho geral



O MODELO RECOMENDADO

Random Forest

89%

de acurácia geral
no conjunto de teste

0,86

AUC — boa capacidade
de distinguir as classes

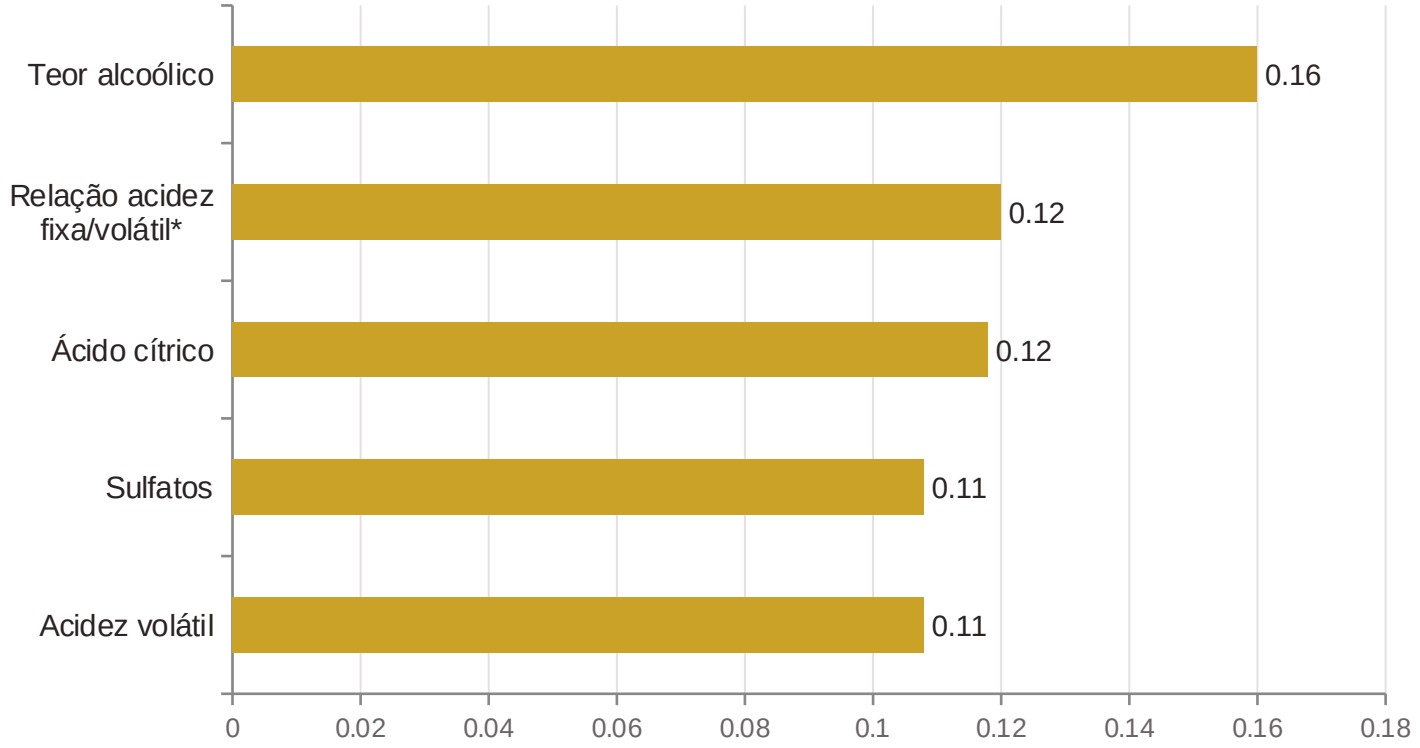
72%

precisão: quando o modelo diz
“alta qualidade”, acerta 72% das vezes

Trade-off a considerar: o Random Forest identifica corretamente apenas **38%** dos vinhos realmente de alta qualidade (deixa passar os demais). A Árvore de Decisão isolada captura **65%** desses vinhos, mas com mais falsos positivos. A escolha entre os dois depende do custo de negócio de cada tipo de erro.

INTERPRETAÇÃO

Teor alcoólico é o fator de maior peso nas previsões do modelo



**Variável criada combinando acidez fixa e volátil, que se mostrou tão relevante quanto as variáveis originais.*

Implicação para a produção

O controle do processo de fermentação — que determina diretamente o teor alcoólico e a acidez volátil — é o ponto de maior alavancagem para elevar a qualidade percebida do produto, mais do que ajustes finos em pH ou densidade.

RECOMENDAÇÕES

O que fazer com esses achados



Monitorar de perto a fermentação

É a etapa que mais influencia teor alcoólico e acidez volátil — os dois fatores de maior peso na qualidade final.



Padronizar sulfatos e ácido cítrico

Também pesam bastante na previsão; pequenos ajustes de processo podem ter retorno desproporcional.



Atenção redobrada aos lotes atípicos

Lotes com açúcar residual ou cloretos fora do padrão merecem inspeção extra antes de seguir na linha.



Usar o modelo como triagem, não veredito

O modelo apoia a priorização de lotes para avaliação sensorial — não substitui o enólogo.

Onde este modelo ainda pode evoluir

Limitações atuais

- Base pequena e desbalanceada: só 159 exemplos de alta qualidade em 1.143 amostras.
- Só variáveis físico-químicas: fatores como safra, tipo de uva e processo de vinificação não entram na conta.
- O modelo ainda deixa passar boa parte dos vinhos de alta qualidade (recall moderado).

Próximos passos sugeridos

- Coletar mais amostras de vinhos de alta qualidade para equilibrar as classes.
- Testar técnicas de balanceamento (ex. SMOTE) e ajuste fino de hiperparâmetros.
- Avaliar outros algoritmos (ex. Gradient Boosting) para melhorar a captura da classe minoritária.



Obrigado

Dados, código e notebook completo disponíveis no repositório do projeto.

Tech Challenge — Fase 2 · Pós-Graduação Data Analytics (FIAP)